ElasticNetCV를 활용한 문서별 지수 예측 및 분류

빅데이터 경영MBA U2017038 김정규 / U2017057 전혜진

과제의 목적

- 문서 택스트 데이터를 이용, 각 카테고리별 점수를 예측하는 모델을 만든다.
- 예측된 점수를 이용, 문서를 카테고리별로 분류한다.

필요 패키지 및 모듈 불러오기

In [1]:

```
import requests
import lxml.html
import datetime
import pandas as pd
import numpy as np
```

네이버 뉴스 크롤링_1

- 20170101 ~ 20171231 기간에 대한 일자 리스트 정의

In [2]:

```
# datetime list 만들기

datetime_list = []

start = datetime.date(2017, 1, 1)
end = datetime.date(2017, 12, 31)
days = [start + datetime.timedelta(days = x) for x in range((end-start).days + 1)]
for day in days:
    datetime_list.append(day.strftime('%Y%m%d'))
```

In [3]:

```
# 일자 리스트 생성 확인
datetime_list[0:10]
```

Out[3]:

```
['20170101',
 '20170102',
 '20170103',
 '20170104',
 '20170105',
 '20170106',
 '20170107',
 '20170108',
 '20170109',
 '20170110']
```

네이버 뉴스 크롤링_2

- 제목 및 내용 가져오기
- 네이버 뉴스 랭킹뉴스 내 정치 첫 번째 기사만 크롤링
- 각 일자별 정치 랭킹뉴스 첫 번째 기사의 링크는 {div : ranking_section} > {li : num1} > {a : href} 노드
- 상기 링크로 접속하여 {h3 : {id : articleTitle}} 노드에서 기사 제목 크롤링
- 상시 링크로 접속하여 {div : {id : articleBodyContents}} 노드에서 기사 내용 크롤링
- <script>, , <image> 등의 태그들을 제거
- 불필요 문자("\n", " " 등) 및 이메일 주소 제거

In [4]:

```
1 url = "http://news.naver.com/main/ranking/popularDay.nhn?rankingType=popular_day&date=20170101"
2 res = requests.get(url)
3 element = lxml.html.fromstring(res.text)
```

In [5]:

```
1 postings = element.cssselect('div.ranking_section li.num1 a')
```

In [6]:

```
1 postings[0].attrib["href"]
```

Out[6]:

'/main/ranking/read.nhn?mid=etc&sid1=111&rankingType=popular_day&oid=001&aid=0008928
841&date=20170101&type=1&rankingSectionId=100&rankingSeq=1'

In [7]:

```
1 news_url = postings[0].attrib["href"]
```

In [8]:

```
1 "http://news.naver.com" + news_url
```

Out[8]:

'http://news.naver.com/main/ranking/read.nhn?mid=etc&sid1=111&rankingType=popular_da
y&oid=001&aid=0008928841&date=20170101&type=1&rankingSectionId=100&rankingSeq=1'

In [9]:

```
1 res_2 = requests.get("http://news.naver.com" + news_url)
```

In [10]:

```
1 element_2 = lxml.html.fromstring(res_2.text)
```

In [11]:

```
1 ## 뉴스 제목을 찾는 방법
2 element_2.cssselect("div.article_info h3")[0].text_content()
```

Out[11]:

'朴대통령 "뇌물죄, 완전히 엮은 것…세월호 허위 걷혀야"(종합)'

In [12]:

```
title = element_2.cssselect("div.article_info h3")[0].text_content()
```

In [13]:

```
## 뉴스 기사 본문을 찾는 방법
element_2.get_element_by_id("articleBodyContents").text_content()
```

```
련해 "완전히 나를 엮은 것"이라고 정면으로 반박했다.  박 대통령은 정유년 새해 첫
날 청와대 상춘재에서 출입기자단과 신년 인사회를 한 자리에서 "누구를 봐줄 생각은 손
톱만큼도 없었고 제 머릿속에서도 없었다"며 이같이 말했다.  박 대통령의 이러한 언
급은 삼성 측이 삼성물산-제일모직 합병 찬성의 대가로 미르·K스프츠 재단에 돈을 기부
하고, 최순실 씨의 딸 정유라씨에 대한 승마훈련 지원 등을 했다는 의혹을 정면으로 반
박한 것이다.  특히 박영수 특별검사팀이 박 대통령을 겨냥해 뇌물죄 의혹을 입증하기
위해 집중적으로 수사하는 상황에서 "엮었다"는 입장을 공식 표명함에 따라 향후 탄핵심
판 및 특검수사 과정에서 강도 높은 대응이 예상된다.  지난달 9일 국회의 탄핵소추안
가결로 직무가 정지된 이후 박 대통령이 참모진과 탄핵심판 대리인단 외에 외부인을 만
난 것은 23일 만이다.  특히 박 대통령은 직무정지 이후 대외 활동을 중단한 채 최순
실 게이트에 대한 직접적인 입장 표명을 자제했으나 이날 사실상의 기자 간담회를 통해
각종 의혹을 조목조목 반박했다.박 대통령은 삼성물산-제일모직 합병 문제에 대해 "공모
나 누구를 봐주기 위해 한 일은 손톱만큼도 없다는 것을 분명히 말씀드릴 수 있다"며
"그것은 어떤 결정이든 간에 국가의 올바른 정책판단이다. 여기저기를 제가 도와주라고
한 적은 없다"고 강조했다.  그러면서 박 대통령은 "특검의 연락이 오면 성실히 (조사
에) 임하겠다"고 덧붙였다.  박 대통령은 최 씨와 연관된 KD 코퍼레이션의 현대차 납
품 특혜 의혹에 대해서도 "여기(KD코퍼레이션)도 기술력이 있다는데 거대한 기업에 끼여
서 제대로 명함 한번 못 내미는 것 아닌가 해서 그럼 알아봐서 실력이 있다면 기회를 가
질 수 있지 않으냐는 차원이었다"고 설명했다.  또한, "(최 씨와 KD코퍼레이션 측이)
아는 사이였다는 것을 부도를 보고 알았다. 제가 누구를 알아도 그 사람의 개인적 이득
```

In [14]:

```
news_article = element_2.get_element_by_id("articleBodyContents")
```

In [15]:

```
news_article
```

Out[15]:

```
<Element div at 0x226393e86d8>
```

In [16]:

```
# Remove all javascript tags and style tags from html with python and the lxml module

from lxml.html.clean import Cleaner
cleaner = Cleaner()
cleaner.javascript = True
cleaner.style = True
cleaner.clean_html(element_2.get_element_by_id("articleBodyContents")).text_content()
```

```
날 청와대 상춘재에서 출입기자단과 신년 인사회를 한 자리에서 "누구를 봐줄 생각은 손
톱만큼도 없었고 제 머릿속에서도 없었다"며 이같이 말했다.  박 대통령의 이러한 언
급은 삼성 측이 삼성물산-제일모직 합병 찬성의 대가로 미르·K스프츠 재단에 돈을 기부
하고, 최순실 씨의 딸 정유라씨에 대한 승마훈련 지원 등을 했다는 의혹을 정면으로 반
박한 것이다.  특히 박영수 특별검사팀이 박 대통령을 겨냥해 뇌물죄 의혹을 입증하기
위해 집중적으로 수사하는 상황에서 "엮었다"는 입장을 공식 표명함에 따라 향후 탄핵심
판 및 특검수사 과정에서 강도 높은 대응이 예상된다.  지난달 9일 국회의 탄핵소추안
가결로 직무가 정지된 이후 박 대통령이 참모진과 탄핵심판 대리인단 외에 외부인을 만
난 것은 23일 만이다.  특히 박 대통령은 직무정지 이후 대외 활동을 중단한 채 최순
실 게이트에 대한 직접적인 입장 표명을 자제했으나 이날 사실상의 기자 간담회를 통해
각종 의혹을 조목조목 반박했다.박 대통령은 삼성물산-제일모직 합병 문제에 대해 "공모
나 누구를 봐주기 위해 한 일은 손톱만큼도 없다는 것을 분명히 말씀드릴 수 있다"며
"그것은 어떤 결정이든 간에 국가의 올바른 정책판단이다. 여기저기를 제가 도와주라고
한 적은 없다"고 강조했다.  그러면서 박 대통령은 "특검의 연락이 오면 성실히 (조사
에) 임하겠다"고 덧붙였다.  박 대통령은 최 씨와 연관된 KD 코퍼레이션의 현대차 납
품 특혜 의혹에 대해서도 "여기(KD코퍼레이션)도 기술력이 있다는데 거대한 기업에 끼여
서 제대로 명함 한번 못 내미는 것 아닌가 해서 그럼 알아봐서 실력이 있다면 기회를 가
질 수 있지 않으냐는 차원이었다"고 설명했다.  또한, "(최 씨와 KD코퍼레이션 측이)
아는 사이였다는 것을 보도를 보고 알았다. 제가 누구를 알아도 그 사람의 개인적 이득
을 위해 부탁하는 것은 절대 금기라며 "아는 건 아는 것이고, 절대 이익을 챙겨주는 일
```

In [17]:

```
## Crawling

news_title_list = []
news_content_list = []

for datetime in datetime_list:
    print(datetime)
    url = "http://news.naver.com/main/ranking/popularDay.nhn?rankingType=popular_day&date=" + d
    res = requests.get(url)
    element = lxml.html.fromstring(res.text)

    # 날짜별 정치 랭킹뉴스 1위 뉴스의 url 가져오기
    postings = element.cssselect('div.ranking_section li.num1 a')
    news_url = postings[0].attrib["href"]

    # 상기 url로 접속하여 뉴스 페이지의 element 저장하기
    res_2 = requests.get("http://news.naver.com" + news_url)
    element_2 = lxml.html.fromstring(res_2.text)

    # 뉴스 제목
    news_title = element_2.cssselect("div.article_info h3")[0].text_content()

    # 뉴스 내용
    news_content = cleaner.clean_html(element_2.get_element_by_id("articleBodyContents")).text_

    #### Data PrepProcessing ##################
    # remove unnecessary characters #
    while news_content.find("₩n") != -1 :
        news_content = news_content.replace("₩n", " ")

    while news_content.find("    ") != -1 :
        news_content = news_content.replace("    ", " ")

    # remove string from email
    if news_content.find("@") !=-1:
        index = news_content.find("@")
        while news_content[index] not in [" ", "."]:
            index = index -1
        news_content = news_content[:index]

    news_content = news_content.strip()

    ########################################

    news_title_list.append(news_title)
    news_content_list.append(news_content)
```

```
20170101
20170102
20170103
20170104
20170105
20170106
20170107
20170108
20170109
20170110
20170111
20170112
```

```
20170113
20170114
20170115
20170116
20170117
20170118
20170119
```

데이터 프레임 생성

In [18]:

```
df = pd.DataFrame(columns=["Date", "Title", "Content"])
df["Date"] = datetime_list
df["Title"] = news_title_list
df["Content"] = news_content_list
```

In [19]:

```
df.head()
```

Out[19]:

	Date	Title	Content
0	20170101	朴대통령 "뇌물죄, 완전히 엮은 것…세월호 허위 걷혀야"(종합)	새해 첫날 청와대서 사실상 기자간담회…직무정지 23일 만에 첫 입장표명"공모나 누구...
1	20170102	정유라, 덴마크서 불법 체류 혐의로 체포… 특검 “송환 협조중” (종합)	[아시아경제 정준영 기자] 이화여대 학사부정 및 삼성 특혜지원 의혹의 수혜자 겸 공...
2	20170103	[단독]정유라, “(주사 아줌마)누구인지 알 것 같다”…현지 답변태도 분석, 사전 ...	덴마크 올보르 법원에서 잠시 휴정중 기자들의 질문에 답변하는 정유라씨 사진=현지교...
3	20170104	[단독]"정유라, 이대학장실 등 교내서 교수 6명에 학점취득 코치받아"	[연합뉴스TV제공]김병욱, 교육부 자료 확인…"학점 좋은이유 모른다더니"담당교수들 ...
4	20170105	윤전추 "기억안나. 몰라. 말못해"… 헌재 "본인범죄 외 답해라"	"외부인 동행 없다" 주장하다 "세월호 당일 미용사 태워왔다" 윤전추 헌재 탄핵심리...

"일자_기사제목" 형식으로 파일 이름 설정 후 "./news" 폴더에 저장

In [20]:

```
import re

for i in range(0, len(df["Content"])):
    title = df["Title"][i]
    # 윈도우 os에서 파일 저장시 특수기호 제한, 정규표현식으로 제목 내 특수기호 제외
    parsed_title = re.sub('[-=."#/?:$]', '', title)
    fname = df["Date"][i] + "_" + parsed_title + ".txt"
    with open("./news/" + fname, "w", encoding = "UTF8") as f:
        f.write(df["Title"][i] + "₩n₩n" + df["Content"][i])
```

라벨링 완료한 데이터 가져오기

- 데이터 라벨링은 조원 2명이 각각 나누어서 시행

- 조원이 뉴스를 직접 읽고 전체 뉴스를 청와대(BH), 국회/정당(Con/Party), 북한(North), 행정(Admin), 국방/외교(Defence/Diplo), 정치일반(Politic) 등 6개 카테고리별 뉴스를 읽고 관련성이 있다고 생각한 점수를 1점에서 10점 사이로 scoring
- Category 컬럼은 부여된 6개의 점수 중 가장 높은 점수를 받은 카테고리를 표시한 것으로 해당 뉴스가 이 카테고리에 분류된 것으로 간주

In [21]:

```
# After labeling ty
labeled_data = pd.read_csv("labeled_dataset.csv", encoding = "UTF8", index_col = 0)
```

In [22]:

```
labeled_data.head()
```

Out[22]:

	Date	Title	BH	Con/Party	North	Admin	Defence/Diplo	Politic	Category
0	20170101	朴대통령 "뇌물죄, 완전히 엮은 것…세월호 허위 걷혀야"(종합)	8	0	0	0	0	2	BH
1	20170102	정유라, 덴마크서 불법 체류 혐의로 체포…특검 "송환 협조중" (종합)	6	0	0	0	0	3	BH
2	20170103	[단독]정유라, "(주사 아줌마)누구인지 알 것 같다"…현지 답변태도 분석, 사전 ...	6	0	0	0	0	3	BH
3	20170104	[단독]"정유라, 이대학장실 등 교내서 교수 6명에 학점취득 코치받아"	5	0	0	0	0	6	Politic
4	20170105	윤전추 "기억안나. 몰라. 말못해"…헌재 "본인범죄 외 답해라"	7	0	0	0	0	2	BH

형태소 분석기 Komoran 사용, tokenize 함수 정의(명사(Noun) 만 사용)

In [23]:

```
from konlpy.tag import Komoran
tag = Komoran()
```

In [24]:

```
def kor_noun(text):
    words = []
    for w in tag.nouns(text):
        if len(w) > 1:
            words.append(w)
    return words
```

TfidfVectorizer 사용 단어들을 vector화 하고 TermDocumentMatrix(df_tfidf) 생성

In [25]:

```
from sklearn.feature_extraction.text import TfidfVectorizer
```

In [26]:

```
text_data_list = df["Content"].astype(str).tolist()
text_data_arr = np.array(["".join(text) for text in text_data_list])
```

In [27]:

```
vectorizer = TfidfVectorizer(min_df = 2, tokenizer = kor_noun, norm = 'l2')
text_data = vectorizer.fit_transform(text_data_arr)
```

```
C:₩Users₩Daniel₩Anaconda3₩lib₩site-packages₩sklearn₩feature_extraction₩text.py:1059:
FutureWarning: Conversion of the second argument of issubdtype from `float` to `np.f
loating` is deprecated. In future, it will be treated as `np.float64 == np.dtype(flo
at).type`.
  if hasattr(X, 'dtype') and np.issubdtype(X.dtype, np.float):
```

In [28]:

```
df_tfidf = pd.DataFrame(text_data.A, columns = vectorizer.get_feature_names())
df_tfidf.head()
```

Out[28]:

	12월 14일	1시간	1월 2일	2007년 남북정상회담	2010년 9월	2012년 10월	2012년 12월	2013년 10월	2013년 12월	2013년 1월	...	휴전선	휴정	휴학	흐름	
0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.000000	0.000000	0.0	0
1	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.000000	0.000000	0.0	0
2	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.072151	0.037957	0.0	0
3	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.000000	0.000000	0.0	0
4	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.000000	0.000000	0.0	0

5 rows × 4412 columns

BH(청와대) 점수에 대한 ElasticNetCV 모델 생성

In [29]:

```
##### 청와대 지수를 TermDocumentMatrix에 붙어 데이터셋으로 생성

df_bh_1 = pd.DataFrame({"BH_y" : list(labeled_data["BH"])})
df_bh = pd.concat([df_tfidf, df_bh_1['BH_y']], axis=1)
```

In [30]:

```
X = df_bh.drop(["BH_y"], axis=1)
y =  df_bh["BH_y"]
```

In [31]:

```
## Data Spliting

from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test  = train_test_split(X, y, test_size=0.2, random_state = 1234)
```

In [32]:

```
X_test.shape
```

Out[32]:

```
(73, 4412)
```

In [33]:

```
## Modeling Training

from sklearn.linear_model import ElasticNetCV
```

In [34]:

```
elastic_bh = ElasticNetCV(cv=3, random_state=0)
```

In [35]:

```
elastic_bh.fit(X_train, y_train)
```

Out[35]:

```
ElasticNetCV(alphas=None, copy_X=True, cv=3, eps=0.001, fit_intercept=True,
       l1_ratio=0.5, max_iter=1000, n_alphas=100, n_jobs=1,
       normalize=False, positive=False, precompute='auto', random_state=0,
       selection='cyclic', tol=0.0001, verbose=0)
```

In [36]:

```
y_pred = elastic_bh.predict(X_test)
```

In [37]:

```
## Model evaluation

from sklearn.metrics import r2_score, mean_squared_error
```

In [38]:

```
r2_score(y_test, y_pred)
```

Out[38]:

0.5381201908514406

In [39]:

```
mean_squared_error(y_test, y_pred)
```

Out[39]:

7.564462792878527

In [40]:

```
elastic_bh.score(X_test, y_test) ## 결정계수값 = 0.55
```

Out[40]:

0.5381201908514406

- 청와대 지수 계산 모델을 ElasticNetCV로 생성한 결과,
- 결정계수는 0.54이고 MSE 값은 7.56 이었음

청와대 지수 예측 모델(elastic_bh)의 예측값과 labeled 데이터값간의 차이를 시각화

In [41]:

```
df_compare = pd.DataFrame({"y_pred" : y_pred.tolist(), "y_labeled" : y_test.tolist()})
```

In [42]:

```
df_compare["x_axis"] = df_compare.index.tolist()
df_compare[["x_axis", "y_labeled", "y_pred"]].head()
```

Out[42]:

	x_axis	y_labeled	y_pred
0	0	9	6.621854
1	1	9	4.825073
2	2	0	3.668346
3	3	10	9.100115
4	4	6	4.988630

In [43]:

```
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
```

In [44]:

```
sns.set(style = "whitegrid")
f, ax = plt.subplots(figsize = (20, 10))

sns.set_color_codes("pastel")
sns.barplot(x = "x_axis", y = "y_labeled", data = df_compare, label = "labeled", color = "b")
sns.barplot(x = "x_axis", y = "y_pred", data = df_compare, label = "pred", color = "r", alpha =

ax.legend(ncol = 2, loc = "upper right", frameon = True)
ax.set(xlim = (0, 73), ylabel = "", xlabel = "Test Data")
sns.despine(left = True, bottom = True)
```

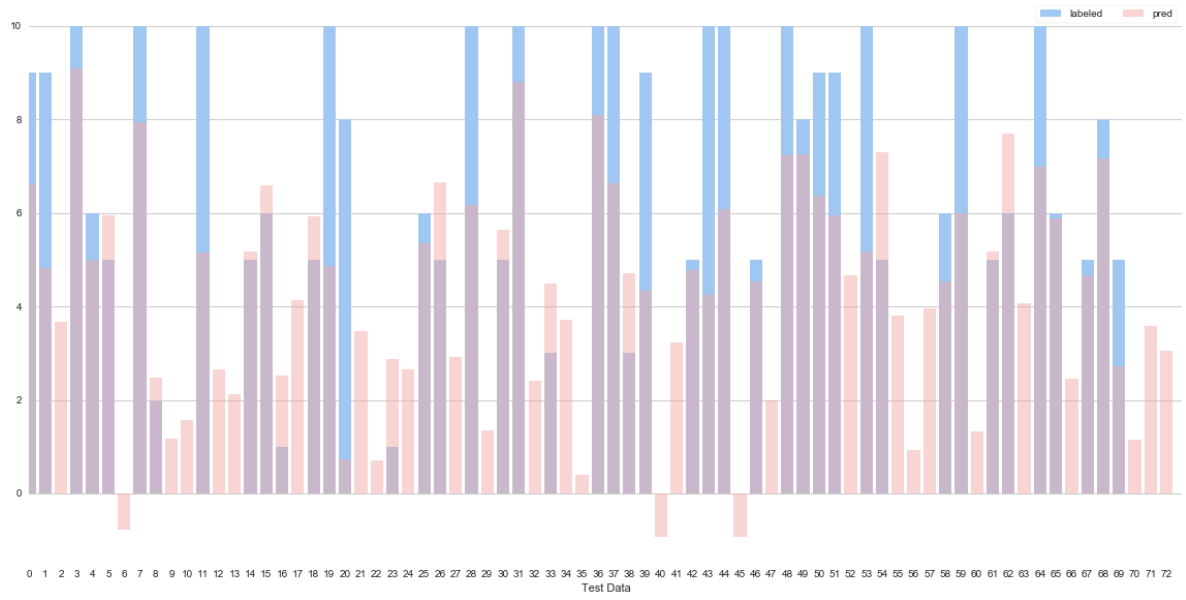

Con/Party(국회/정당) 점수에 대한 ElasticNetCV 모델 생성

In [45]:

```
#####  국회/정당 지수를 TermDocumentMatrix에 붙어 데이터셋으로 생성

df_con_party_1 = pd.DataFrame({"Con/Party_y" : list(labeled_data["Con/Party"])})
df_con_party = pd.concat([df_tfidf, df_con_party_1['Con/Party_y']], axis=1)
```

In [46]:

```
X = df_con_party.drop(["Con/Party_y"], axis=1)
y =  df_con_party["Con/Party_y"]
```

In [47]:

```
## Data Spliting
X_train, X_test, y_train, y_test  = train_test_split(X, y, test_size=0.2, random_state = 1234)
```

In [48]:

```
## Modeling Training

from sklearn.linear_model import ElasticNetCV
```

In [49]:

```
elastic_con_party = ElasticNetCV(cv=3, random_state=0)
```

In [50]:

```
elastic_con_party.fit(X_train, y_train)
```

Out[50]:

```
ElasticNetCV(alphas=None, copy_X=True, cv=3, eps=0.001, fit_intercept=True,
       l1_ratio=0.5, max_iter=1000, n_alphas=100, n_jobs=1,
       normalize=False, positive=False, precompute='auto', random_state=0,
       selection='cyclic', tol=0.0001, verbose=0)
```

In [51]:

```
y_pred = elastic_con_party.predict(X_test)
```

In [52]:

```
## Model evaluation

from sklearn.metrics import r2_score, mean_squared_error
```

In [53]:

```
r2_score(y_test, y_pred)
```

Out[53]:

```
0.5447377768713692
```

In [54]:

```
mean_squared_error(y_test, y_pred)
```

Out[54]:

```
7.707762862659286
```

- 국회/정당 지수 계산 모델을 ElasticNetCV로 생성한 결과,
- 결정계수는 0.54이고 MSE 값은 7.70 이었음

국회/정당 지수 예측 모델(elastic_con_party) 예측값과 labeled 데이터값간의 차이를 시각화

In [55]:

```
df_compare = pd.DataFrame({"y_pred" : y_pred.tolist(), "y_labeled" : y_test.tolist()})
```

In [56]:

```
df_compare["x_axis"] = df_compare.index.tolist()
df_compare[["x_axis", "y_labeled", "y_pred"]].head()
```

Out[56]:

	x_axis	y_labeled	y_pred
0	0	10	7.365913
1	1	0	2.593460
2	2	0	1.857930
3	3	9	8.159385
4	4	2	0.130726

In [57]:

```
sns.set(style = "whitegrid")
f, ax = plt.subplots(figsize = (20, 10))

sns.set_color_codes("pastel")
sns.barplot(x = "x_axis", y = "y_labeled", data = df_compare, label = "labeled", color = "b")
sns.barplot(x = "x_axis", y = "y_pred", data = df_compare, label = "pred", color = "r", alpha =

ax.legend(ncol = 2, loc = "upper right", frameon = True)
ax.set(xlim = (0, 73), ylabel = "", xlabel = "Test Data")
sns.despine(left = True, bottom = True)
```

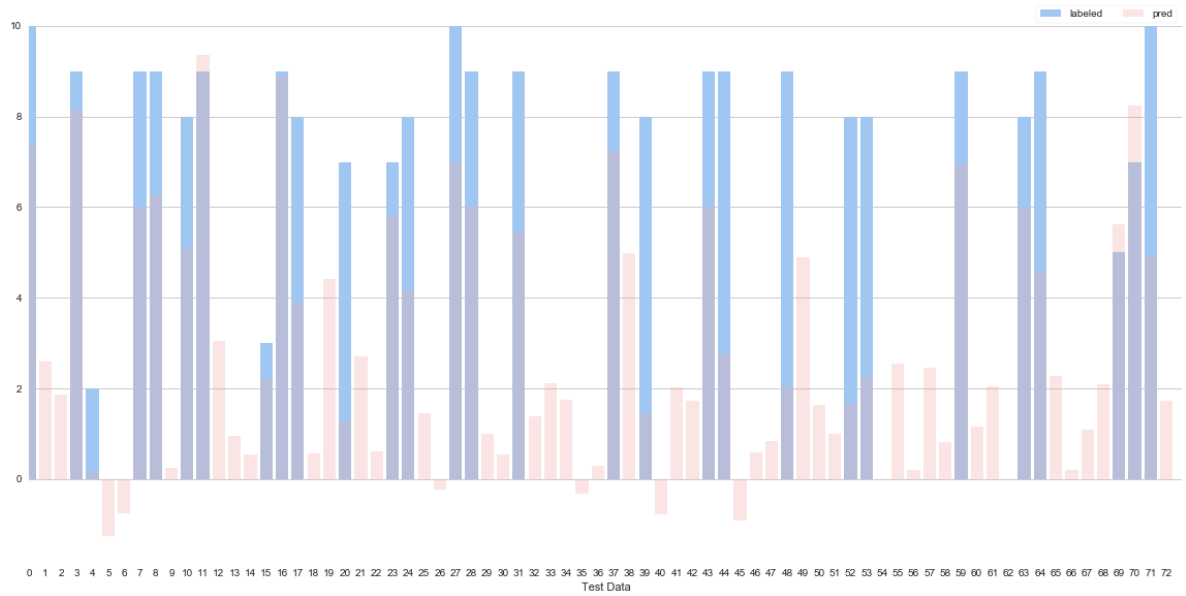

North(북한)지수 산출 모델 생성

In [58]:

```
# 북한 지수를 TermDocumentMatrix에 붙어 데이터셋으르 생성

df_north_1 = pd.DataFrame({"North_y" : list(labeled_data["North"])})
df_north = pd.concat([df_tfidf, df_north_1['North_y']], axis=1)
```

In [59]:

```
X = df_north.drop(["North_y"], axis=1)
y =  df_north["North_y"]
```

In [60]:

```
## Data Spliting
X_train, X_test, y_train, y_test  = train_test_split(X, y, test_size=0.2, random_state = 1234)
```

In [61]:

```
## Modeling Training

from sklearn.linear_model import ElasticNetCV
```

In [62]:

```
elastic_north = ElasticNetCV(cv=3, random_state=0)
```

In [63]:

```
elastic_north.fit(X_train, y_train)
```

Out[63]:

```
ElasticNetCV(alphas=None, copy_X=True, cv=3, eps=0.001, fit_intercept=True,
       l1_ratio=0.5, max_iter=1000, n_alphas=100, n_jobs=1,
       normalize=False, positive=False, precompute='auto', random_state=0,
       selection='cyclic', tol=0.0001, verbose=0)
```

In [64]:

```
y_pred = elastic_north.predict(X_test)
```

In [65]:

```
## Model evaluation

from sklearn.metrics import r2_score, mean_squared_error
```

In [66]:

```
r2_score(y_test, y_pred)
```

Out[66]:

```
0.5028839194272506
```

In [67]:

```
mean_squared_error(y_test, y_pred)
```

Out[67]:

```
4.942242437369912
```

- 북한 지수 계산 모델을 ElasticNetCV로 생성한 결과,
- 결정계수는 0.5이고 MSE 값은 4.94 이었음

북한 지수 예측모델(elastic_north) 예측값과 labeled 데이터값간의 차이를 시각화

In [68]:

```
df_compare = pd.DataFrame({"y_pred" : y_pred.tolist(), "y_labeled" : y_test.tolist()})
```

In [69]:

```
df_compare["x_axis"] = df_compare.index.tolist()
df_compare =  df_compare[["x_axis", "y_labeled", "y_pred"]]
```

In [70]:

```
sns.set(style = "whitegrid")
f, ax = plt.subplots(figsize = (20, 10))

sns.set_color_codes("pastel")
sns.barplot(x = "x_axis", y = "y_labeled", data = df_compare, label = "labeled", color = "b")
sns.barplot(x = "x_axis", y = "y_pred", data = df_compare, label = "pred", color = "r", alpha =

ax.legend(ncol = 2, loc = "upper right", frameon = True)
ax.set(xlim = (0, 73), ylabel = "", xlabel = "Test Data")
sns.despine(left = True, bottom = True)
```

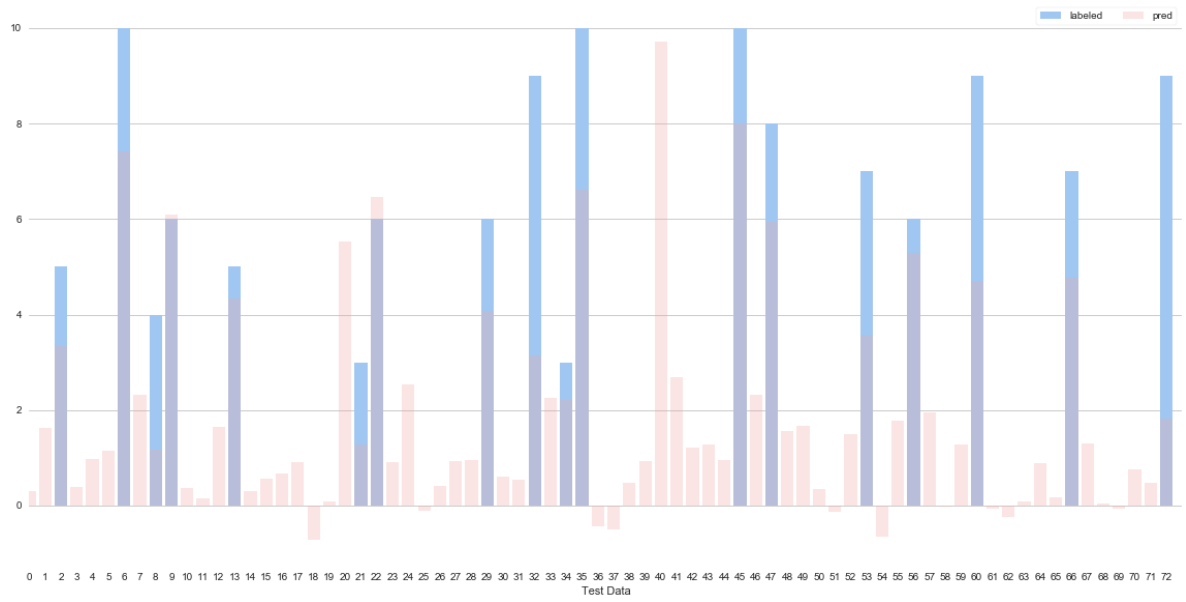

Admin(행정) 지수 산출 모델 생성

In [71]:

```
# 행정 지수를 TermDocumentMatrix에 붙어 데이터셋으르 생성

df_admin_1 = pd.DataFrame({"Admin_y" : list(labeled_data["Admin"])})
df_admin = pd.concat([df_tfidf, df_admin_1['Admin_y']], axis=1)
```

In [72]:

```
X = df_admin.drop(["Admin_y"], axis=1)
y =  df_admin["Admin_y"]
```

In [73]:

```
## Data Spliting
X_train, X_test, y_train, y_test  = train_test_split(X, y, test_size=0.2, random_state = 1234)
```

In [74]:

```
## Modeling Training

from sklearn.linear_model import ElasticNetCV
```

In [75]:

```
elastic_admin = ElasticNetCV(cv=3, random_state=0)
```

In [76]:

```
elastic_admin.fit(X_train, y_train)
```

Out[76]:

```
ElasticNetCV(alphas=None, copy_X=True, cv=3, eps=0.001, fit_intercept=True,
       l1_ratio=0.5, max_iter=1000, n_alphas=100, n_jobs=1,
       normalize=False, positive=False, precompute='auto', random_state=0,
       selection='cyclic', tol=0.0001, verbose=0)
```

In [77]:

```
y_pred = elastic_admin.predict(X_test)
```

In [78]:

```
## Model evaluation

from sklearn.metrics import r2_score, mean_squared_error
```

In [79]:

```
r2_score(y_test, y_pred)
```

Out[79]:

```
0.026252949379969248
```

In [80]:

```
mean_squared_error(y_test, y_pred)
```

Out[80]:

```
11.941877415316474
```

- 행정지수 예측 모델의 결정계수는 0.026이고, MSE 값은 11.94 임
- 결정계수 값이 0.03으로 모델이 데이터를 거의 설명하지 못하고 있음
- 행정이라는 주제가 다른 주제들과 비교시 그 의미가 추상적이고 광범위하여 모델이 값을 예측하기 곤란했을 거라 사료됨

행정지수 예측모델(elastic_admin)의 예측값과 labeled 데이터값간의 차이를 시각화

In [81]:

```
df_compare = pd.DataFrame({"y_pred" : y_pred.tolist(), "y_labeled" : y_test.tolist()})
```

In [82]:

```
df_compare["x_axis"] = df_compare.index.tolist()
df_compare =  df_compare[["x_axis", "y_labeled", "y_pred"]]
```

In [83]:

```
sns.set(style = "whitegrid")
f, ax = plt.subplots(figsize = (20, 10))

sns.set_color_codes("pastel")
sns.barplot(x = "x_axis", y = "y_labeled", data = df_compare, label = "labeled", color = "b")
sns.barplot(x = "x_axis", y = "y_pred", data = df_compare, label = "pred", color = "r", alpha =

ax.legend(ncol = 2, loc = "upper right", frameon = True)
ax.set(xlim = (0, 73), ylabel = "", xlabel = "Test Data")
sns.despine(left = True, bottom = True)
```

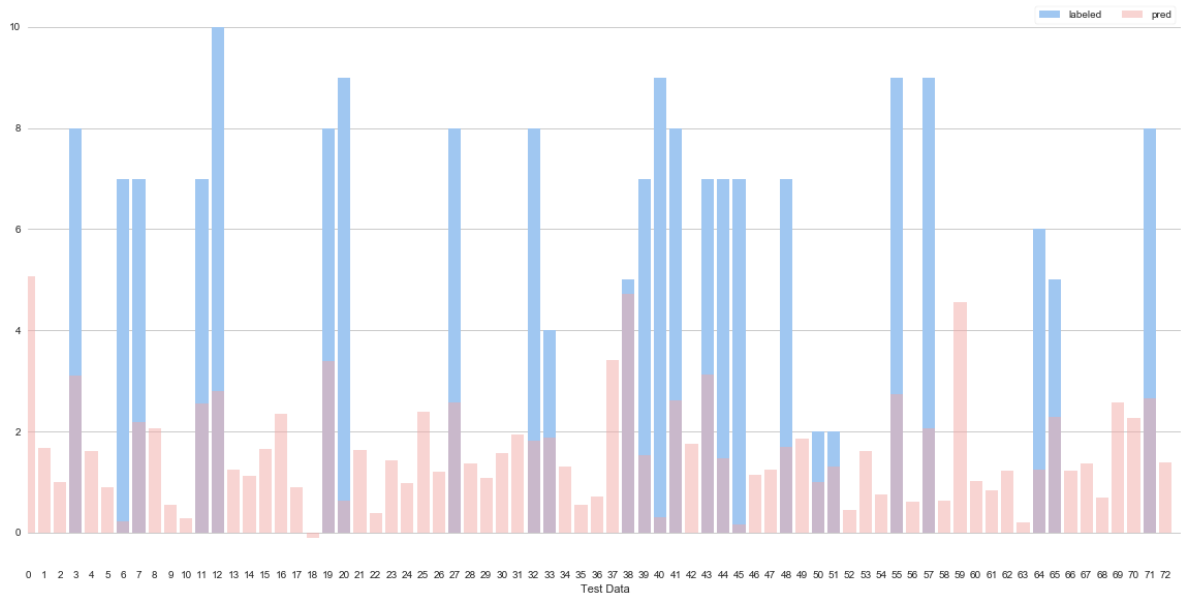

국방/외교 지수 산출 모델 생성

In [84]:

```
# 국방/외교 지수를 TermDocumentMatrix에 붙어 데이터셋으로 생성

df_defence_diplo_1 = pd.DataFrame({"Defence/Diplo_y" : list(labeled_data["Defence/Diplo"])})
df_defence_diplo = pd.concat([df_tfidf, df_defence_diplo_1['Defence/Diplo_y']], axis=1)
```

In [85]:

```
X = df_defence_diplo.drop(["Defence/Diplo_y"], axis=1)
y = df_defence_diplo["Defence/Diplo_y"]
```

In [86]:

```
## Data Spliting
X_train, X_test, y_train, y_test  = train_test_split(X, y, test_size=0.2, random_state = 1234)
```

In [87]:

```
## Modeling Training

from sklearn.linear_model import ElasticNetCV
```

In [88]:

```
elastic_defence_diplo = ElasticNetCV(cv=3, random_state=0)
```

In [89]:

```
elastic_defence_diplo.fit(X_train, y_train)
```

Out[89]:

```
ElasticNetCV(alphas=None, copy_X=True, cv=3, eps=0.001, fit_intercept=True,
       l1_ratio=0.5, max_iter=1000, n_alphas=100, n_jobs=1,
       normalize=False, positive=False, precompute='auto', random_state=0,
       selection='cyclic', tol=0.0001, verbose=0)
```

In [90]:

```
y_pred = elastic_defence_diplo.predict(X_test)
```

In [91]:

```
## Model evaluation

from sklearn.metrics import r2_score, mean_squared_error
```

In [92]:

```
r2_score(y_test, y_pred)
```

Out[92]:

```
0.6311010424815219
```

In [93]:

```
mean_squared_error(y_test, y_pred)
```

Out[93]:

```
6.018680983765554
```

- 국방/외교 지수 계산 모델(elastic_defence_diplo)을 ElasticNetCV로 생성한 결과,
- 결정계수는 0.63이고 MSE 값은 6.02 이었음
- 가장 성능이 우수한 모델이 이었는데, 이는 국방/외교에 대한 기사들이 다른 기사들보다 쉽게 구분되는 주제이었기 때문이었을거라고 사료됨.

국방/외교 지수 예측 모델(elastic_defence_diplo) 예측값과 labeled 데이터값간의 차이를 시각화

In [94]:

```
df_compare = pd.DataFrame({"y_pred" : y_pred.tolist(), "y_labeled" : y_test.tolist()})
```

In [95]:

```
df_compare["x_axis"] = df_compare.index.tolist()
df_compare =  df_compare[["x_axis", "y_labeled", "y_pred"]]
```

In [96]:

```
sns.set(style = "whitegrid")
f, ax = plt.subplots(figsize = (20, 10))

sns.set_color_codes("pastel")
sns.barplot(x = "x_axis", y = "y_labeled", data = df_compare, label = "labeled", color = "b")
sns.barplot(x = "x_axis", y = "y_pred", data = df_compare, label = "pred", color = "r", alpha =

ax.legend(ncol = 2, loc = "upper right", frameon = True)
ax.set(xlim = (0, 73), ylabel = "", xlabel = "Test Data")
sns.despine(left = True, bottom = True)
```

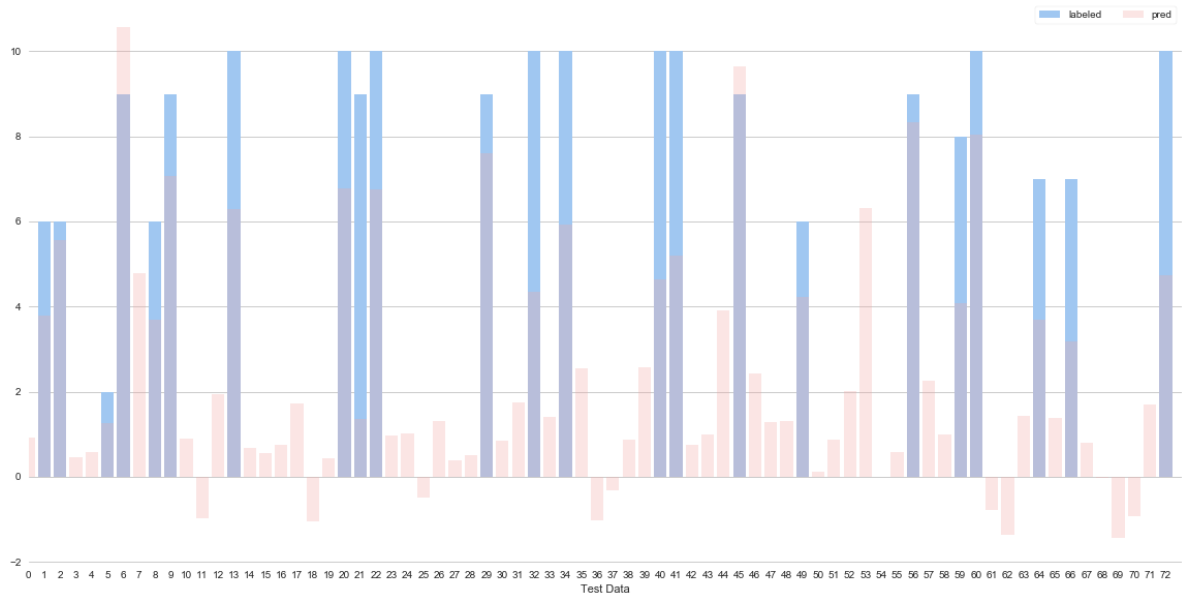

Politic(정치일반)지수 산출 모델 생성

In [97]:

```
# 정치일반 지수를 TermDocumentMatrix에 붙어 데이터셋으로 생성

df_politic_1 = pd.DataFrame({"Politic_y" : list(labeled_data["Politic"])})
df_politic = pd.concat([df_tfidf, df_politic_1['Politic_y']], axis=1)
```

In [98]:

```
X = df_politic.drop(["Politic_y"], axis=1)
y = df_politic["Politic_y"]
```

In [99]:

```
## Data Spliting
X_train, X_test, y_train, y_test  = train_test_split(X, y, test_size=0.2, random_state = 1234)
```

In [100]:

```
## Modeling Training

from sklearn.linear_model import ElasticNetCV
```

In [101]:

```
elastic_politic = ElasticNetCV(cv=3, random_state=0)
```

In [102]:

```
elastic_politic.fit(X_train, y_train)
```

Out[102]:

```
ElasticNetCV(alphas=None, copy_X=True, cv=3, eps=0.001, fit_intercept=True,
       l1_ratio=0.5, max_iter=1000, n_alphas=100, n_jobs=1,
       normalize=False, positive=False, precompute='auto', random_state=0,
       selection='cyclic', tol=0.0001, verbose=0)
```

In [103]:

```
y_pred = elastic_politic.predict(X_test)
```

In [104]:

```
## Model evaluation

from sklearn.metrics import r2_score, mean_squared_error
```

In [105]:

```
r2_score(y_test, y_pred)
```

Out[105]:

```
0.17361207263422473
```

In [106]:

```
mean_squared_error(y_test, y_pred)
```

Out[106]:

```
9.75072623323423
```

- 정치 일반 지수 예측 모델(elastic_politic)의 결정계수는 0.17이고, MSE 값은 9.75 임
- 결정계수 값이 0.17으로 모델이 데이터를 거의 설명하지 못하고 있음
- 정치일반이라는 주제가 행정과 같이 다른 주제들과 비교시 그 의미가 추상적이고 광범위하여 모델이 값을 예측하기 곤란했을 거라 사료됨

정치일반지수 예측모델(elastic_politic) 예측값과 labeled 데이터값간의 차이를 시각화

In [107]:

```
df_compare = pd.DataFrame({"y_pred" : y_pred.tolist(), "y_labeled" : y_test.tolist()})
```

In [108]:

```
df_compare["x_axis"] = df_compare.index.tolist()
df_compare =  df_compare[["x_axis", "y_labeled", "y_pred"]]
```

In [109]:

```
sns.set(style = "whitegrid")
f, ax = plt.subplots(figsize = (20, 10))

sns.set_color_codes("pastel")
sns.barplot(x = "x_axis", y = "y_labeled", data = df_compare, label = "labeled", color = "b")
sns.barplot(x = "x_axis", y = "y_pred", data = df_compare, label = "pred", color = "r", alpha =

ax.legend(ncol = 2, loc = "upper right", frameon = True)
ax.set(xlim = (0, 73), ylabel = "", xlabel = "Test Data")
sns.despine(left = True, bottom = True)
```

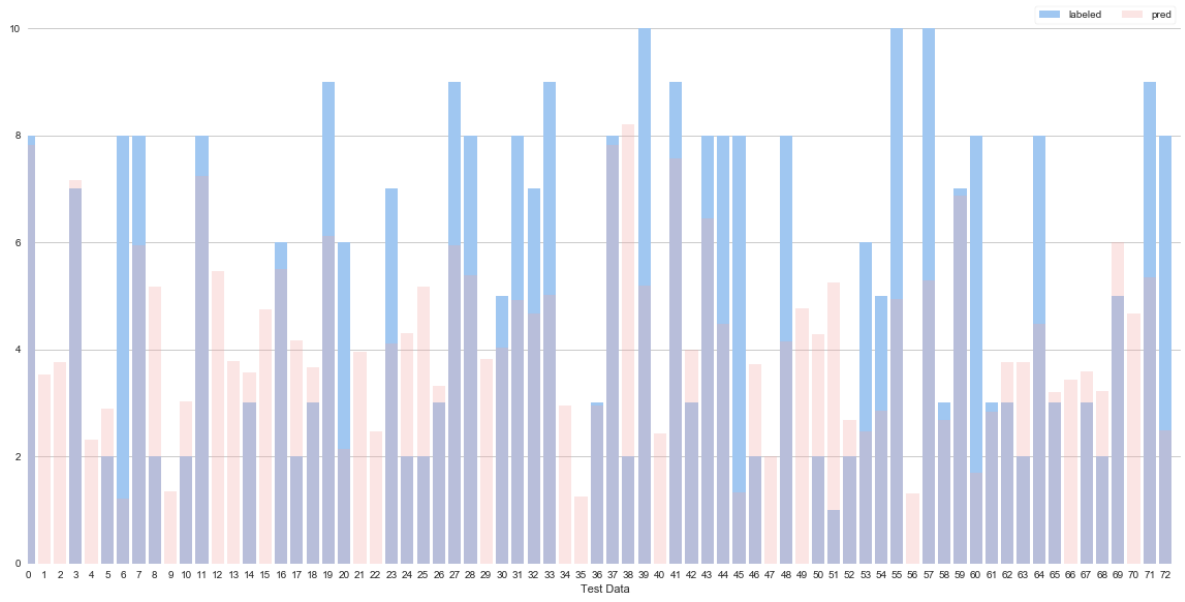

임의의 파일 가져오기와 각 모델에 대입, 각 지수 산출해보기

In [110]:

```
# "20170101_차대통령 뇌물죄, 완전히 엮은 것…세월호 허위 걷혀야(종합).txt" 파일은 2017.01.01 2
with open("./test_news/20170101_7시간해명 집중한 대통령...돌연 기자 간담회, 왜.txt", "rb") as c
    data = data.read()
    data = data.decode("utf-8")
```

In [111]:

```
1 data
```

말한 겁니다 WrWnWrWn[앵커]WrWnWrWn"대통령으로서 할 일은 했다"고 하면서도 관저 출근을 하지 않은 점은 인정을 한 것이거든요?WrWnWrWn[기자]WrWnWrWn네, 세월호 당일 왜 관저에만 있었냐는 기자의 질문에, 박 대통령은 현장은 바쁠 것 같아 본관에 가지 않았다고 밝혔는데요. WrWnWrWn관저에서 30~40분에 한 번씩 전화로 보고도 받고 지시도 했다, 그리고 다른 업무도 같이 봤다고 말했는데요.WrWnWrWn대형 국가적 참사에 대응해야할 최종 책임자가 바로 대통령인데 본관에 출근해서 회의를 주재하고 직접 지휘를 하면 업무에 차질이 빚어질 것 같아서 안 했다는 해명인데, 아무리 봐도 이해가 어려운 부분입니다. WrWnWrWn[앵커]WrWnWrWn관저에서는 어떤 조치를 했다고 했습니까?WrWnWrWn[기자]WrWnWrWn구체적으로 어떤 보고를 받고 어떻게 지휘했는지도 오늘 해명에는 없었습니다. WrWnWrWn그러니까 이전에 청와대 대변인이 주장을 했던 내용에서 진전된 내용은 없이 정상적으로 일했다는 주장을 반복한 건데요.WrWnWrWn특히 중대본에 바로 가지 않은 것에 대해선 "경호실에서 필수시간이 필요하다고 해서 마음대로 움직이지 못했다"고 말했습니다.WrWnWrWn경호의 특수성을 감안한다 하더라도 2시간동안 움직이지 못했다는 것은 이해하기 힘들다는 지적이 나옵니다.WrWnWrWn[앵커]WrWnWrWn오늘 대통령이 한 말 중에 눈에 띄는 것이 W'철학과 소신W' 인데요. 처음 나온 말이죠?WrWnWrWn[기자]WrWnWrWn대통령은 각종 의혹에 대해 "국정운영의 철학과 소신을 갖고 쭉 해온 일이다"라고 했습니다. WrWnWrWn대통령의 해명은 담화 때마다 말이 조금씩 바뀌고 있는데요. 검찰 수사 상황하고도 연관이 되는 걸로 보입니다. WrWnWrWn처음 대국민 담화 때는 "꼼꼼하게 챙겨보고자 하는 순수한 마음으로 한 일이다"라고 했다가, 3차 때는 "사익을 추구하지 않았고 작은 사심도 품지 않았다"라고 주장했는데, 본격적인 탄핵심리를 앞두고 W'철학과 소신W'에 따

In [112]:

```
1 df_test_doc = pd.DataFrame({"Content" : [data]})
```

In [113]:

```
1 test_doc_data_list = df_test_doc["Content"].astype(str).tolist()
2 test_doc_data_arr = np.array(["".join(text) for text in test_doc_data_list])
```

In [114]:

```
1 vectorizer = TfidfVectorizer(max_df = 2, tokenizer=kor_noun, norm = 'l2')
2 test_doc_data = vectorizer.fit_transform(test_doc_data_arr)
```

```
C:WUsersWDanielWAnaconda3WlibWsite-packagesWsklearnWfeature_extractionWtext.py:1059:
FutureWarning: Conversion of the second argument of issubdtype from `float` to `np.f
loating` is deprecated. In future, it will be treated as `np.float64 == np.dtype(flo
at).type`.
  if hasattr(X, 'dtype') and np.issubdtype(X.dtype, np.float):
```

In [115]:

```
1 test_doc_df_tfidf = pd.DataFrame(test_doc_data.A, columns = vectorizer.get_feature_names())
2 test_doc_df_tfidf.shape
```

Out[115]:

(1, 157)

임의로 선택된 데이터(data)에서 형성된 Tfidf를 지수 각 6개 산출 모델(regr_bh)에 대입 후 점수 산출 하기

In [116]:

```
1 X_test_doc = test_doc_df_tfidf
```

모델을 생성시 사용한 TermDocumentMatrix의 단어는 4412개 이어서 새로 대입되는 data의 TDM(단어컬럼수가 157개)을 기존 훈련 데이터 형식과 맞추는 작업이 필요

- 대입되는 data의 tfidf 데이터 프레임을 transpose하고 index를 새로운 "words"컬럼에 삽입하고 동 tfdif 내 값들을 "weight" 컬럼으로 정의하여 새로운 데이터 프레임 df_2를 정의
- 모델 생성시 사용했던 df_tfidf의 컬럼 이름들을 새로운 "words" 컬럼에 삽입하여 새로운 데이터 프레임 df_3를 정의
- df_3를 기준으로 키값 "words"에 대해 "left outer" 조인 시행 후 데이터 프레임 "merged_df_4"를 정의
- "merged_df_4" DF의 index를 "words" 컬럼으로 대체하고 "words" 컬럼으로 삭제 후 새로운 데이터 프레임 "df_4"를 정의
- "df_4"를 다시 tranpose하고 NaN값들을 0으로 대체하여 최종 모델에 대입할 "X_test_doc" 데이터를 생성

In [117]:

```
# 대입되는 data의 tfidf를 transpose하고 index를 새로운 "words"컬럼에 삽입, 동 tfdif 내 값들을 "
df_2 = test_doc_df_tfidf.transpose()
df_2["words"] = df_2.index
df_2 = df_2.rename(columns = {0 : "weights"})
df_2_list = df_2["words"].tolist()
```

In [118]:

```
# 모델 생성시 사용했던 df_tfidf의 컬럼 이름들을 새로운 "words" 컬럼에 삽입하여 새로운 데이터 프
df_large_words = pd.DataFrame(df_tfidf.columns.values, columns = ["words"])
df_3 = df_large_words
df_3_list = df_3["words"].tolist()
```

In [119]:

```
## large words set 과 small words set의 교집합 범위는 143개, 즉 data의 단어 컬럼수가 157개에서
len(set(df_2_list) & set(df_3_list))
```

Out[119]:

147

In [120]:

```
set(df_2_list) - (set(df_2_list) & set(df_3_list)) # 대입될 데이터에는 있지만 훈련용 데이터 셋에
```

Out[120]:

{'건지', '남발', '노트북', '미팅', '사심', '새해 첫날', '순수한 마음', '정치부', '통
치행위', '한광옥'}

In [121]:

```
# "merged_df_4" DF의 index를 "words" 컬럼으로 대체하고 "words" 컬럼으로 삭제 후 새로운 데이터 프
merged_df_4 = pd.merge(df_3, df_2[["weights", "words"]], how = "left", on = ["words"])
```

In [122]:

```
# "df_4"를 다시 tranpose하고 NaN값들을 0으로 대체하여 최종 모델에 대입할 "X_test_doc" 데이터를
merged_df_4.index =merged_df_4["words"].tolist()
df_4 = merged_df_4.drop(["words"], axis = 1)
X_test_doc = df_4.transpose().fillna(0)
```

In [123]:

```
# 훈련용 데이터셋에서 사용된 단어컬럼들의 형식으로 재정의
X_test_doc
```

Out[123]:

	12월14일	1시간	1월2일	2007년남북정상회담	2010년9월	2012년10월	2012년12월	2013년10월	2013년12월	2013년1월	...	휴전선	휴정	휴학	흐름	흔적	
weights	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0

1 rows × 4412 columns

각 지출 모델에 대입하여 점수 확인

In [124]:

```
elastic_bh.predict(X_test_doc)[0]
```

Out[124]:

8.595485090973739

In [125]:

```
elastic_con_party.predict(X_test_doc)[0]
```

Out[125]:

3.4408796129761843

In [126]:

```
elastic_north.predict(X_test_doc)[0]
```

Out[126]:

-1.5028328371933684

In [127]:

```
elastic_admin.predict(X_test_doc)[0]
```

Out[127]:

0.4143353233798872

국방/외교 지수 산출 모델에 대입하여 국방/외교 지수 산출

In [128]:

```
elastic_defence_diplo.predict(X_test_doc)[0]
```

Out[128]:

0.15168268723811 94

정치일반 지수 산출 모델에 대입하여 정치일반 지수 산출

In [129]:

```
elastic_politic.predict(X_test_doc)[0]
```

Out[129]:

3.1516784101620874

- 가장 높은 점수는 8.59인 청와대 지수 점수 이므로 data는 청와대와 관련이 있는 뉴스로 판단 가능

6개 지수 자동 산출 함수 생성

In [130]:

```
def auto_6_scores_of_text(fname):

    ## ".txt 파일 읽어오기" ##########################################################################
    with open(fname, "rb") as data:
        data = data.read()
        data = data.decode("utf-8")

    ## 읽은 파일 내용에 대한 tfidf DataFrame 만들기 ##########################################
    df_test_doc = pd.DataFrame({"Content"  : [data]})
    test_doc_data_list = df_test_doc["Content"].astype(str).tolist()
    test_doc_data_arr = np.array(["".join(text) for text in test_doc_data_list])
    vectorizer = TfidfVectorizer(max_df = 2, tokenizer = kor_noun, norm = 'l2')
    test_doc_data = vectorizer.fit_transform(test_doc_data_arr)
    test_doc_df_tfidf = pd.DataFrame(test_doc_data.A, columns = vectorizer.get_feature_names())

    ## X_test_doc 데이터 포맷을 모델의 입력 데이터 포맷과 일치하는 작업 ######################

    ## 읽은 데이터에 대한 부분 단어 데이터 프레임 만들기
    df_partial_words = test_doc_df_tfidf.transpose()
    df_partial_words["words"] = df_partial_words.index
    df_partial_words = df_partial_words.rename(columns = {0 : "weights"})

    ## 전체 단어 데이터 프레임(left)과 부분 단어 데이터 프레임(right)를 서로 "left outer join"
    df_total_words = pd.DataFrame(df_tfidf.columns.values, columns = ["words"])
    merged_total_partial_df_by_words = pd.merge(df_total_words,
                                                df_partial_words[["weights", "words"]],
                                                how = "left",
                                                on = ["words"])

    ## "left outer" 조인 후 인덱스를 전체 단어로 대체
    merged_total_partial_df_by_words.index = merged_total_partial_df_by_words["words"].tolist()

    ## "words" 컬럼 삭제
    total_partial_df_by_words = merged_total_partial_df_by_words.drop(["words"], axis = 1)

    ## "transpose()"하고 "NaN" 값을 0으로 대체, 최종 모델 입력 데이터 생성
    X_test_doc = total_partial_df_by_words.transpose().fillna(0)

    ## 각 모델별 지수 산출 ##########################################################################

    ## 청와대(bh) 지수
    BH_score = elastic_bh.predict(X_test_doc)[0]
    print("청와대 지수 : ", BH_score)

    ## 국회/정당(con_party) 지수
    Con_Party_score = elastic_con_party.predict(X_test_doc)[0]
    print("국회/정당 지수 : ", Con_Party_score)

    ## 북한(north) 지수
    North_score = elastic_north.predict(X_test_doc)[0]
    print("북한 지수 : ", North_score)

    ## 행정(admin) 지수
    Admin_score = elastic_admin.predict(X_test_doc)[0]
    print("행정 지수 : ", Admin_score)

    ## 국방/외교(defence_diplo) 지수
    Defence_diplo_score = elastic_defence_diplo.predict(X_test_doc)[0]
    print("국방/외교 지수 : ", Defence_diplo_score)
```

```
60
61      ## 정치(politic) 지수
62      Politic_score = elastic_politic.predict(X_test_doc)[0]
63      print("정치일반 지수 : ", Politic_score, "₩n")
64
65      ## 각 지수 데이터 프레임 생성
66      global df_scores
67      global df_score_transposed
68      df_scores = pd.DataFrame.from_items([("BH", [BH_score]),
69                                           ("Con/Party", [Con_Party_score]),
70                                           ("North", [North_score]),
71                                           ("Admin", [Admin_score]),
72                                           ("Defense/Diplo", [Defence_diplo_score]),
73                                           ("Politic", [Politic_score])])
74      df_score_index = ["Scores"]
75      df_scores.index =df_score_index
76      df_score_transposed = df_scores.transpose()
```

In [131]:

```
1  auto_6_scores_of_text("./test_news/20170101_7시간해명 집중한 대통령...돌연 기자 간담회, 왜.txt"
```

```
청와대 지수 :  8.595485090973739
국회/정당 지수 :  3.4408796129761843
북한 지수 :  -1.5028328371933684
행정 지수 :  0.4143353233798872
국방/외교 지수 :  0.1516826872381194
정치일반 지수 :  3.1516784101620874


C:₩Users₩Daniel₩Anaconda3₩lib₩site-packages₩sklearn₩feature_extraction₩text.py:1059:
FutureWarning: Conversion of the second argument of issubdtype from `float` to `np.f
loating` is deprecated. In future, it will be treated as `np.float64 == np.dtype(flo
at).type`.
  if hasattr(X, 'dtype') and np.issubdtype(X.dtype, np.float):
```

In [132]:

```
1  df_scores
```

Out[132]:

	BH	Con/Party	North	Admin	Defense/Diplo	Politic
Scores	8.595485	3.44088	-1.502833	0.414335	0.151683	3.151678

레이터 챠트 그리기

In [133]:

```
1  df_scores
```

Out[133]:

	BH	Con/Party	North	Admin	Defense/Diplo	Politic
Scores	8.595485	3.44088	-1.502833	0.414335	0.151683	3.151678

In [134]:

```
import matplotlib.pyplot as plt
from math import pi
% matplotlib inline
```

In [135]:

```
df_radar = df_scores.reset_index().rename(columns = {"index" : "Group"})
categories_radar = list(df_radar)[1:]
N_radar = len(categories_radar)

values_radar = df_radar.loc[0].drop("Group").values.flatten().tolist()
values_radar += values_radar[:1]

angles_radar = [n / float(N_radar)*2*pi for n in range(N_radar)]
angles_radar += angles_radar[:1]

ax_radar = plt.subplot(111, polar = True)

plt.xticks(angles_radar[:-1], categories_radar, color = "grey", size = 8)

ax_radar.set_rlabel_position(0)
plt.yticks([1, 2, 3, 4, 5, 6, 7, 8, 9],
           ["1", "2", "3", "4", "5", "6", "7", "8", "9"],
           color = "grey", size = 7)
plt.ylim(0, 10)

ax_radar.plot(angles_radar, values_radar, linewidth = 1, linestyle = "solid")
ax_radar.fill(angles_radar, values_radar, "b", alpha=0.1)
```

Out[135]:

[<matplotlib.patches.Polygon at 0x226549c59b0>]

In [136]:

```
##### 점수 계산 및 레이더 챠트 함수 만들기
```

In [137]:

```
def auto_6_scores_radar_chart(fname):

    ## ".txt 파일 읽어오기" ##########################################################################
    with open(fname, "rb") as data:
        data = data.read()
        data = data.decode("utf-8")

    ## 읽은 파일 내용에 대한 tfidf DataFrame 만들기 ##################################################
    df_test_doc = pd.DataFrame({"Content"  : [data]})
    test_doc_data_list = df_test_doc["Content"].astype(str).tolist()
    test_doc_data_arr = np.array(["".join(text) for text in test_doc_data_list])
    vectorizer = TfidfVectorizer(max_df = 2, tokenizer = kor_noun, norm = 'l2')
    test_doc_data = vectorizer.fit_transform(test_doc_data_arr)
    test_doc_df_tfidf = pd.DataFrame(test_doc_data.A, columns = vectorizer.get_feature_names())

    ## X_test_doc 데이터 포맷을 모델의 입력 데이터 포맷과 일치하는 작업 ##########################

    ## 읽은 데이터에 대한 부분 단어 데이터 프레임 만들기
    df_partial_words = test_doc_df_tfidf.transpose()
    df_partial_words["words"] = df_partial_words.index
    df_partial_words = df_partial_words.rename(columns = {0 : "weights"})

    ## 전체 단어 데이터 프레임(left)과 부분 단어 데이터 프레임(right)를 서로 "left outer join"
    df_total_words = pd.DataFrame(df_tfidf.columns.values, columns = ["words"])
    merged_total_partial_df_by_words = pd.merge(df_total_words,
                                                df_partial_words[["weights", "words"]],
                                                how = "left",
                                                on = ["words"])

    ## "left outer" 조인 후 인덱스를 전체 단어로 대체
    merged_total_partial_df_by_words.index = merged_total_partial_df_by_words["words"].tolist()

    ## "words" 컬럼 삭제
    total_partial_df_by_words = merged_total_partial_df_by_words.drop(["words"], axis = 1)

    ## "transpose()"하고 "NaN" 값을 0으로 대체, 최종 모델 입력 데이터 생성
    X_test_doc = total_partial_df_by_words.transpose().fillna(0)

    ## 각 모델별 지수 산출 ###########################################################################

    ## 청와대(bh) 지수
    if elastic_bh.predict(X_test_doc)[0] >= 0:
        BH_score = elastic_bh.predict(X_test_doc)[0]
    else:
        BH_score = 0

    print("청와대 지수 : ", BH_score)

    ## 국회/정당(con_party) 지수
    if elastic_con_party.predict(X_test_doc)[0] >= 0:
        Con_Party_score = elastic_con_party.predict(X_test_doc)[0]
    else:
        Con_Party_score = 0

    print("국회/정당 지수 : ", Con_Party_score)

    ## 북한(north) 지수
    if elastic_north.predict(X_test_doc)[0] >= 0:
        North_score = elastic_north.predict(X_test_doc)[0]
```

```
    else:
        North_score = 0

    print("북한 지수 : ", North_score)

    ## 행정(admin) 지수
    if elastic_admin.predict(X_test_doc)[0] >= 0:
        Admin_score = elastic_admin.predict(X_test_doc)[0]
    else:
        Admin_score = 0

    print("행정 지수 : ", Admin_score)

    ## 국방/외교(defence_diplo) 지수
    if elastic_defence_diplo.predict(X_test_doc)[0] >= 0:
        Defence_diplo_score = elastic_defence_diplo.predict(X_test_doc)[0]
    else:
        Defence_diplo_score = 0

    print("국방/외교 지수 : ", Defence_diplo_score)

    ## 정치(politic) 지수
    if elastic_politic.predict(X_test_doc)[0] >= 0:
        Politic_score = elastic_politic.predict(X_test_doc)[0]
    else:
        Politic_score = 0

    print("정치일반 지수 : ", Politic_score, "₩n₩n")

    ## 각 지수 데이터 프레임 생성
    global df_scores
    global df_score_transposed
    df_scores = pd.DataFrame.from_items([("BH", [BH_score]),
                                         ("Con/Party", [Con_Party_score]),
                                         ("North", [North_score]),
                                         ("Admin", [Admin_score]),
                                         ("Defense/Diplo", [Defence_diplo_score]),
                                         ("Politic", [Politic_score])])
    df_score_index = ["Scores"]
    df_scores.index =df_score_index
    df_score_transposed = df_scores.transpose()

    ## radar chart 그리기 ##################################################################
    df_radar = df_scores.reset_index().rename(columns = {"index" : "Group"})
    categories_radar = list(df_radar)[1:]
    N_radar = len(categories_radar)

    values_radar = df_radar.loc[0].drop("Group").values.flatten().tolist()
    values_radar += values_radar[:1]

    angles_radar = [n / float(N_radar)*2*pi for n in range(N_radar)]
    angles_radar += angles_radar[:1]

    ax_radar = plt.subplot(111, polar = True)
    plt.xticks(angles_radar[:-1], categories_radar, color = "grey", size = 8)

    ax_radar.set_rlabel_position(0)
    plt.yticks([1, 2, 3, 4, 5, 6, 7, 8, 9], ["1", "2", "3", "4", "5", "6", "7", "8", "9"],
           color = "grey", size = 7)
    plt.ylim(0, 10)

```

```
121     ax_radar.plot(angles_radar, values_radar, linewidth = 1, linestyle = "solid")
122     ax_radar.fill(angles_radar, values_radar, "b", alpha=0.1)
```

In [138]:

```
1 auto_6_scores_radar_chart("./test_news/20170101_7시간해명 집중한 대통령...돌연 기자 간담회, 왜.
```

```
청와대 지수 :  8.595485090973739
국회/정당 지수 :  3.4408796129761843
북한 지수 :  0
행정 지수 :  0.4143353233798872
국방/외교 지수 :  0.1516826872381194
정치일반 지수 :  3.1516784101620874
```

```
C:WUsersWDanielWAnaconda3WlibWsite-packagesWsklearnWfeature_extractionWtext.py:1059:
FutureWarning: Conversion of the second argument of issubdtype from `float` to `np.f
loating` is deprecated. In future, it will be treated as `np.float64 == np.dtype(flo
at).type`.
  if hasattr(X, 'dtype') and np.issubdtype(X.dtype, np.float):
```

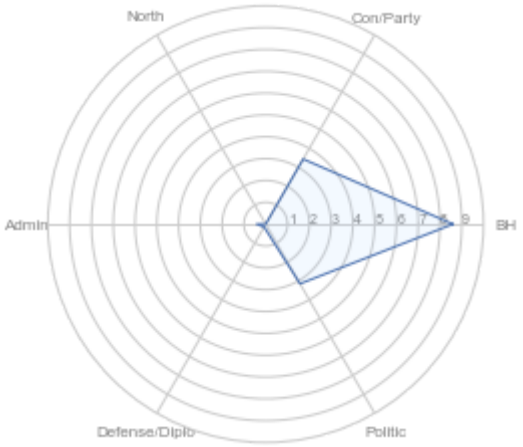

예측점수 중 가장 많은 점수로 기사를 분류 후 실제 분류와 비교(정확도 계산)

In [139]:

```
def auto_6_scores_of_text_without_print(fname):

    ## ".txt 파일 읽어오기" ##########################################################################
    with open(fname, "rb") as data:
        data = data.read()
        data = data.decode("utf-8")

    ## 읽은 파일 내용에 대한 tfidf DataFrame 만들기 ##################################################
    df_test_doc = pd.DataFrame({"Content"  : [data]})
    test_doc_data_list = df_test_doc["Content"].astype(str).tolist()
    test_doc_data_arr = np.array(["".join(text) for text in test_doc_data_list])
    vectorizer = TfidfVectorizer(max_df = 2, tokenizer = kor_noun, norm = 'l2')
    test_doc_data = vectorizer.fit_transform(test_doc_data_arr)
    test_doc_df_tfidf = pd.DataFrame(test_doc_data.A, columns = vectorizer.get_feature_names())

    ## X_test_doc 데이터 포맷을 모델의 입력 데이터 포맷과 일치하는 작업 ##########################

    ## 읽은 데이터에 대한 부분 단어 데이터 프레임 만들기
    df_partial_words = test_doc_df_tfidf.transpose()
    df_partial_words["words"] = df_partial_words.index
    df_partial_words = df_partial_words.rename(columns = {0 : "weights"})

    ## 전체 단어 데이터 프레임(left)과 부분 단어 데이터 프레임(right)를 서로 "left outer join"
    df_total_words = pd.DataFrame(df_tfidf.columns.values, columns = ["words"])
    merged_total_partial_df_by_words = pd.merge(df_total_words,
                                                df_partial_words[["weights", "words"]],
                                                how = "left",
                                                on = ["words"])

    ## "left outer" 조인 후 인덱스를 전체 단어로 대체
    merged_total_partial_df_by_words.index = merged_total_partial_df_by_words["words"].tolist()

    ## "words" 컬럼 삭제
    total_partial_df_by_words = merged_total_partial_df_by_words.drop(["words"], axis = 1)

    ## "transpose()"하고 "NaN" 값을 0으로 대체, 최종 모델 입력 데이터 생성
    X_test_doc = total_partial_df_by_words.transpose().fillna(0)

    ## 각 모델별 지수 산출 ###########################################################################

    ## 청와대(bh) 지수
    global BH_score
    BH_score = elastic_bh.predict(X_test_doc)[0]

    ## 국회/정당(con_party) 지수
    global Con_Party_score
    Con_Party_score = elastic_con_party.predict(X_test_doc)[0]

    ## 북한(north) 지수
    global North_score
    North_score = elastic_north.predict(X_test_doc)[0]

    ## 행정(admin) 지수
    global Admin_score
    Admin_score = elastic_admin.predict(X_test_doc)[0]

    ## 국방/외교(defence_diplo) 지수
    global Defence_diplo_score
    Defence_diplo_score = elastic_defence_diplo.predict(X_test_doc)[0]
```

```
60
61      ## 정치(politic) 지수
62      global Politic_score
63      Politic_score = elastic_politic.predict(X_test_doc)[0]
```

In [140]:

```
1 from os import listdir
2 from os.path import isfile, join
3 myfiles = [f for f in listdir("./news") if isfile(join("./news", f))]
```

In [141]:

```
1 myfiles.sort()
```

In [142]:

```
1 len(myfiles)
```

Out[142]:

365

In [143]:

```
1  BH_score_list = []
2  Con_Party_score_list = []
3  North_score_list = []
4  Admin_score_list = []
5  Defence_Diplo_score_list = []
6  Politic_score_list = []
7
8  for i in myfiles:
9
10     # 읽어올 파일 이름 만들기
11     fname = "./news/" + i
12
13     ## 읽은 파일 내용에 대한 각 분야별 지수 계산(auto_6_scores_of_text_without_print 함수 이용)
14     auto_6_scores_of_text_without_print(fname)
15
16     BH_score_list.append(BH_score)
17     Con_Party_score_list.append(Con_Party_score)
18     North_score_list.append(North_score)
19     Admin_score_list.append(Admin_score)
20     Defence_Diplo_score_list.append(Defence_diplo_score)
21     Politic_score_list.append(Politic_score)
```

```
C:₩Users₩Daniel₩Anaconda3₩lib₩site-packages₩sklearn₩feature_extraction₩text.py:1059:
FutureWarning: Conversion of the second argument of issubdtype from `float` to `np.f
loating` is deprecated. In future, it will be treated as `np.float64 == np.dtype(flo
at).type`.
  if hasattr(X, 'dtype') and np.issubdtype(X.dtype, np.float):
```

In [144]:

```
df_test = pd.DataFrame(columns=["BH", "Con/Party", "North", "Admin",
                                "Defence/Diplo", "Politic"])
df_test["BH"] = BH_score_list
df_test["Con/Party"] = Con_Party_score_list
df_test["North"] = North_score_list
df_test["Admin"] = Admin_score_list
df_test["Defence/Diplo"] = Defence_Diplo_score_list
df_test["Politic"] = Politic_score_list
```

In [145]:

```
df_test.head()
```

Out[145]:

	BH	Con/Party	North	Admin	Defence/Diplo	Politic
0	9.726184	2.902576	-0.967088	0.115460	-0.574612	3.375722
1	6.287002	-0.720626	0.266411	0.503647	-0.303105	3.079211
2	6.594995	0.822646	-0.416149	0.564240	0.315885	3.513176
3	4.563722	0.529652	0.637710	1.536373	-0.090278	4.438874
4	6.905071	0.355169	-0.368948	0.065061	-0.313791	2.170892

In [146]:

```
df_test["Category(predicted)"] = df_test.idxmax("columns")
```

In [147]:

```
len(datetime_list)
```

Out[147]:

365

In [148]:

```
df_test.shape
```

Out[148]:

(365, 7)

In [149]:

```
df_test["Date"] = datetime_list
```

In [150]:

```
df_test.head()
```

Out[150]:

	BH	Con/Party	North	Admin	Defence/Diplo	Politic	Category(predicted)	
0	9.726184	2.902576	-0.967088	0.115460	-0.574612	3.375722	BH	2017
1	6.287002	-0.720626	0.266411	0.503647	-0.303105	3.079211	BH	2017
2	6.594995	0.822646	-0.416149	0.564240	0.315885	3.513176	BH	2017
3	4.563722	0.529652	0.637710	1.536373	-0.090278	4.438874	BH	2017
4	6.905071	0.355169	-0.368948	0.065061	-0.313791	2.170892	BH	2017

In [151]:

```
df_predicted = df_test[["Date", "BH", "Con/Party", "North",  "Admin", "Defence/Diplo", "Politic
df_predicted.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 365 entries, 0 to 364
Data columns (total 8 columns):
Date                  365 non-null object
BH                    365 non-null float64
Con/Party             365 non-null float64
North                 365 non-null float64
Admin                 365 non-null float64
Defence/Diplo         365 non-null float64
Politic               365 non-null float64
Category(predicted)   365 non-null object
dtypes: float64(6), object(2)
memory usage: 22.9+ KB
```

In [152]:

```
df_predicted["Date"] = df_predicted["Date"].tolist()
df_predicted.head()
```

Out[152]:

	Date	BH	Con/Party	North	Admin	Defence/Diplo	Politic	Category(predi
0	20170101	9.726184	2.902576	-0.967088	0.115460	-0.574612	3.375722	
1	20170102	6.287002	-0.720626	0.266411	0.503647	-0.303105	3.079211	
2	20170103	6.594995	0.822646	-0.416149	0.564240	0.315885	3.513176	
3	20170104	4.563722	0.529652	0.637710	1.536373	-0.090278	4.438874	
4	20170105	6.905071	0.355169	-0.368948	0.065061	-0.313791	2.170892	

In [153]:

```
df_comparison = pd.concat([labeled_data, df_predicted["Category(predicted)"].to_frame()], axis=
df_comparison
```

Out[153]:

	Date	Title	Category	Category(predicted)
0	20170101	朴대통령 "뇌물죄, 완전히 엮은 것...세월호 허위 걷혀야"(종합)	BH	BH
1	20170102	정유라, 덴마크서 불법 체류 혐의로 체포…특검 "송환 협조중" (종합)	BH	BH
2	20170103	[단독]정유라, "(주사 아줌마)누구인지 알 것 같다"...현지 답변태도 분석, 사전 ...	BH	BH
3	20170104	[단독]"정유라, 이대학장실 등 교내서 교수 6명에 학점취득 코치받아"	Politic	BH
4	20170105	윤전추 "기억안나. 몰라. 말못해"... 헌재 "본인 범죄 외 답해라"	BH	BH
5	20170106	강제송환 절차 시작...정유라 '조건없는 귀국 의사' 없는 듯(종합)	Politic	Politic

In [154]:

```
## 예측된 분류 결고와 불일치하는 데이터의 갯수
len(df_comparison[df_comparison["Category"] != df_comparison["Category(predicted)"]])
```

Out[154]:

60

In [155]:

```
## 예측된 분류 결고와 일치하는 데이터의 갯수
len(df_comparison[df_comparison["Category"] == df_comparison["Category(predicted)"]])
```

Out[155]:

305

In [156]:

```
## 정확도 계산
305/365
```

Out[156]:

0.8356164383561644

ElasticNetCV를 활용한 각 분류별 회귀모델을 만들어 이를 이용해 문서를 분류한 결고, 약 84%의 정확도로 분류 가능하였음.